

II MCSM

Modelagem Computacional no Sertão Mineiro



PPGMCS
Programa de Pós-Graduação em
Modelagem Computacional e Sistemas

PREVISÃO DE NDVI PARA CANA-DE-AÇUCAR UTILIZANDO ABORDAGEM HÍBRIDA DE FILTRO KALMAN E GRADIENT BOOSTING

Primeiro Autor¹ – Gerson Santos Souza, email-gerson_santos20@hotmail.com

Segundo Autor¹ – Maurilio José Inácio, email-maurilio.inacio@unimontes.br

¹Universidade Estadual de Montes Claros, UNIMONTES - Montes Claros, MG, Brasil

Resumo. A monitorização e previsão do desenvolvimento das culturas são pilares da agricultura de precisão, permitindo a otimização de recursos e a tomada de decisões estratégicas. O Índice de Vegetação por Diferença Normalizada (NDVI), derivado de imagens de satélite, é um dos indicadores mais utilizados para avaliar a saúde e o vigor da vegetação. No entanto, as séries temporais de NDVI são frequentemente afetadas por ruídos causados por condições atmosféricas, como nuvens e aerossóis, que podem distorcer a representação real do estado da cultura. Para superar a limitação imposta por dados ruidosos à precisão dos modelos preditivos, este estudo propõe uma análise comparativa rigorosa de três arquiteturas. Foram avaliados o Filtro de Kalman, como técnica de suavização; o Gradient Boosting, como modelo de aprendizado de máquina; e uma abordagem Híbrida, que sinergiza as duas metodologias com o objetivo de determinar qual dos sistemas apresenta o desempenho superior em termos de robustez o que se tornou evidente com o modelo Híbrido.

Palavras-chave: NDVI, Filtro de Kalman, Gradient Boosting, Séries Temporais, Agricultura de Precisão.

1. INTRODUÇÃO

Este artigo investiga a hipótese de que a combinação de um filtro de suavização de séries temporais com um modelo de aprendizado de máquina pode gerar resultados mais robustos para a previsão de NDVI em áreas demarcadas de cultura de cana de açúcar também chamados de talhões. Para isso, comparamos o desempenho de um modelo de Gradient Boosting, que utiliza dados meteorológicos, com uma abordagem híbrida. Nesta abordagem, o Filtro de Kalman é empregado para suavizar a série temporal de NDVI, e o resultado dessa suavização é utilizado como uma nova característica (*feature*) para enriquecer os dados de entrada do modelo Gradient Boosting. O objetivo é demonstrar que, ao fornecer ao modelo de aprendizado de máquina um sinal menos ruidoso e representativo da dinâmica da cultura, é possível alcançar uma maior acurácia preditiva.

2. METODOLOGIAS DE ANÁLISE DE SÉRIES TEMPORAIS E PREVISÃO

2.1. Filtro de Kalman para Suavização de Séries Temporais

O Filtro de Kalman é um algoritmo recursivo ideal para extrair um sinal de interesse a partir de medições ruidosas (WELCH; BISHOP, 2006). No contexto de dados de sensoriamento remoto, ele é um algoritmo eficaz para suavizar ruído em séries temporais, como os dados de NDVI, que podem ser afetados por condições atmosféricas (LI et al., 2020). O filtro opera em um ciclo de duas etapas: predição, onde projeta o estado atual para o próximo instante de tempo, e atualização, onde corrige essa predição com base em uma nova medição. A base matemática reside em um modelo de espaço de estados, com uma equação de transição (1) e uma de observação (2). A incerteza é gerenciada por matrizes de covariância para o estado (P), o ruído do processo (Q) e o ruído da medição (R). Ao ajustar os pesos entre a predição do modelo e a medição ruidosa, o filtro produz uma estimativa suavizada que representa de forma mais fiel a trajetória real da variável.

2.2. Gradient Boosting para Previsão

O Gradient Boosting é um poderoso algoritmo de aprendizado de máquina do tipo *ensemble*, amplamente utilizado para problemas de regressão e classificação (FRIEDMAN, 2001). Sua força reside na construção sequencial de modelos "fracos", tipicamente árvores de decisão. Cada nova árvore é treinada para corrigir os erros (resíduos) cometidos pelo conjunto de árvores anterior. Este processo iterativo permite que o modelo final capture relações complexas e não-lineares nos dados. Em aplicações agrícolas, o Gradient Boosting tem se mostrado altamente eficaz na previsão de produtividade de culturas ao integrar dados de múltiplas fontes, como informações meteorológicas e de sensoriamento remoto (CAI et al., 2019; DE OLIVEIRA et al., 2024).

3. APLICAÇÃO DE SÉRIES TEMPORAIS NA AGRICULTURA

A abordagem deste trabalho é puramente baseada em dados, utilizando o NDVI como um indicador da saúde e crescimento da vegetação, correlacionando-o com dados meteorológicos. O NDVI foi calculado a partir de imagens do satélite Sentinel-2, que oferece alta resolução espacial e temporal, ideal para o monitoramento agrícola. A série temporal de NDVI obtida através do Google Earth Engine foi então utilizada de duas maneiras: como a variável-alvo para os modelos de previsão e como a base para a engenharia de características no modelo híbrido. O Filtro de Kalman foi aplicado como um passo de pré-processamento e suavização para gerar uma versão com menos ruído da série temporal de NDVI, que serviu como entrada para o modelo híbrido.

A eficácia da etapa de suavização é visualmente demonstrada na Figura 1. Nela, a série temporal de NDVI original (linha contínua) exibe uma alta variabilidade e ruído, características das medições de satélite. Em contrapartida, a saída do Filtro de Kalman (linha tracejada) apresenta uma curva mais suave que captura a tendência fenológica principal da cultura, filtrando flutuações abruptas que não representam o crescimento real da vegetação. Este sinal limpo é fundamental para a performance do modelo híbrido.




Figura 1: Série Temporal de NDVI Original (linhas contínuas) e a versão suavizada pelo Filtro de Kalman (linhas tracejadas) para os três talhões (área de terra definida dentro de uma propriedade rural) analisados. Fonte: O autor.

4. RESULTADOS E DISCUSSÃO

4.1. Desenvolvimento de um Modelo Híbrido

A racionalidade da abordagem híbrida reside na hipótese de que, ao fornecer ao modelo Gradient Boosting não apenas os dados meteorológicos, mas também uma versão suavizada e com menos ruído do próprio NDVI (a saída do Filtro de Kalman), o modelo consegue aprender as relações de forma mais eficaz e fazer previsões mais estáveis. O NDVI suavizado atua como uma feature de alta qualidade que encapsula a tendência de crescimento da cultura, permitindo que o Gradient Boosting se concentre em modelar a influência de fatores externos (clima) sobre essa tendência, em vez de tentar simultaneamente filtrar o ruído e aprender os padrões de previsão. Este conceito de engenharia de características é fundamental para melhorar o desempenho de modelos preditivos na agricultura (KHAN 2020).

4.2. Análise de Desempenho Comparativa

Para ilustrar os benefícios práticos dessas abordagens, foi realizada uma análise comparativa de desempenho. Os resultados, apresentados na Figura 4, comparam um Filtro de Kalman para suavização de séries temporais, um modelo de aprendizado de máquina (Gradient Boosting) e um Modelo Híbrido que integra conceitos de ambas as abordagens. Na Figura 4 fica demonstrado que o Modelo Híbrido demonstrou superioridade como, alcançando o menor Erro Médio Absoluto (MAE) e Erro Médio Quadrático (RMSE), e o maior Coeficiente de Determinação (R^2), indicando uma capacidade de previsão mais precisa e robusta.

A análise visual corrobora os resultados das métricas. A Figura 2 apresenta a comparação entre o NDVI Real e o NDVI Predito pelo modelo Gradient Boosting no conjunto de teste. Embora o modelo consiga capturar a tendência sazonal geral, ele exibe dificuldades em acompanhar as variações mais agudas e tende a subestimar ou superestimar os picos de crescimento, como observado para o "Talhão_3_Vizinho_Leste", onde a predição se mantém em um patamar médio.




Figura 2: Comparação entre o NDVI Real (linhas contínuas) e o NDVI Predito pelo modelo Gradient Boosting (linhas tracejadas) no conjunto de teste, para cada talhão. Fonte: O autor.

Em contrapartida, a Figura 3 demonstra o desempenho superior do Modelo Híbrido. Ao incorporar a série de NDVI suavizada pelo Filtro de Kalman como uma variável de entrada, o modelo se torna mais responsivo à dinâmica real da cultura. As linhas tracejadas (predição) seguem as linhas contínuas (real) com maior fidelidade, especialmente nos períodos de maior variação, o que justifica os melhores valores de R^2 , RMSE e MAE apresentados na Figura 4.




Figura 3: Comparação entre o NDVI Real (linhas contínuas) e o NDVI Predito pelo Modelo Híbrido (linhas tracejadas) no conjunto de teste, destacando a maior acurácia da abordagem híbrida. Fonte: O autor.




Figura 4: Gráficos comparativos das métricas de desempenho — Erro Médio Quadrático (RMSE), Erro Médio Absoluto (MAE) e Coeficiente de Determinação (R^2) — para os três modelos avaliados no conjunto de teste. Fonte: O autor.

5. CONCLUSÃO

Este trabalho demonstrou a eficácia de uma abordagem híbrida, que combina o Filtro de Kalman e o Gradient Boosting, para a previsão de NDVI em talhões da cultura de cana-de-açúcar. Os resultados confirmam que o uso do NDVI suavizado pelo Filtro de Kalman como uma característica de entrada melhora significativamente o desempenho do modelo Gradient Boosting em comparação com o uso isolado do mesmo. A abordagem híbrida se mostrou mais precisa e robusta, destacando o valor da extração de características no pré-processamento de séries temporais ruidosas para modelos de aprendizado de máquina.

Como trabalho futuros sugere-se exploração de outros algoritmos de aprendizado de máquina e técnicas de suavização mais avançadas. Além disso, a inclusão de mais variáveis, como dados de solo e informações de manejo agrícola, pode aprimorar ainda mais a precisão dos modelos. A continuidade do trabalho aponta para modelos cada vez mais integrados, capazes de assimilar dados de múltiplas fontes para fornecer previsões acuradas que apoiem a tomada de decisão na agricultura de precisão.

REFERÊNCIAS

- CAI, J. *et al.* Integrating meteorological and remote sensing data for yield prediction of winter wheat in China using machine learning methods. **Science of The Total Environment**, v. 693, p. 133546, 2019.
- DE OLIVEIRA, G. *et al.* Sugarcane Yield Estimation Using Remote Sensing and Machine Learning: A Systematic Review. **Remote Sensing**, v. 16, n. 5, p. 863, 2024.
- FRIEDMAN, J. H. Greedy function approximation: A gradient boosting machine. **Annals of Statistics**, v. 29, n. 5, p. 1189-1232, 2001.
- JÖNSSON, P.; EKLUNDH, L. T. A program for analyzing time-series of satellite sensor data. **Computers & Geosciences**, v. 30, n. 8, p. 833-845, 2004.
- KHAN, S. *et al.* A Hybrid Machine Learning approach for crop yield prediction through feature engineering and model stacking. **Computers and Electronics in Agriculture**, v. 174, p. 105520, 2020.
- LI, X. *et al.* Time-series reconstruction of remote sensing data using a Kalman filter-based method. **Remote Sensing Letters**, v. 11, n. 1, p. 1-10, 2020.
- ROUSE, J. W. *et al.* Monitoring vegetation systems in the Great Plains with ERTS. In: NASA. **Special Publication**, n. 351, p. 309, 1974.
- WELCH, G.; BISHOP, G. **An Introduction to the Kalman Filter**. Chapel Hill, NC: University of North Carolina at Chapel Hill, 2006. (Technical Report, TR 95-041).