



RECONHECIMENTO DE ATIVIDADES HUMANAS: UMA ABORDAGEM PRÁTICA COM REDES NEURAIS PROFUNDAS E FUSÃO DE CARACTERÍSTICAS VISUAIS E POSTURAIS

Gerson Santos Souza¹ – gerson_santos20@hotmail.com

Maurilio José Inácio¹ – maurilio.inacio@unimontes.br

¹ Universidade Estadual de Montes Claros – Montes Claros – MG

Resumo. Este trabalho propõe a aplicação de rede neurais profundas no reconhecimento de atividades humanas a partir de vídeos, associadas à fusão de características visuais e posturais. Na abordagem proposta é utilizada a rede neural convolucional modelo EfficientNetV2 para extrair as características visuais e o framework MediaPipe para extrair as características posturais do vídeo. Os dados resultantes são combinados e fornecidos para classificação da atividade utilizando a rede neural recorrente modelo LSTM. Experimentos realizados empregando vídeos das bases de dados UCF-101 Dataset e UR Fall Detection Dataset comprovaram que a abordagem proposta alcança desempenho superior a outras abordagens, tornando-a uma alternativa viável para aplicações diversas.

Palavras-chave: Reconhecimento de Atividades Humanas, Redes Neurais Profundas, Fusão de características.

1. INTRODUÇÃO

O reconhecimento de atividades humanas, ou *Human Activity Recognition* (HAR), a partir de vídeo representa uma importante ferramenta no campo da visão computacional, cujo uso tem crescido exponencialmente em diversas áreas e associada à incorporação da Inteligência Artificial (IA). A capacidade de identificar e categorizar ações humanas em sequências de vídeo é fundamental para interações avançadas entre humanos e computadores, abrangendo aplicações diversas, desde a vigilância e segurança patrimonial, até o monitoramento de saúde de idosos. Nessas aplicações, um sistema computacional eficaz de reconhecimento contínuo de atividades em vídeo deve ser capaz de manter o contexto temporal, permitindo inferir ações em novos *frames* com base no histórico acumulado (Kim *et al.*, 2023).

A aplicação de tecnologias HAR em contextos sociais, como no auxílio a idosos, é particularmente relevante. Estatísticas demonstram que quedas são uma das principais causas de lesões fatais em pessoas acima de 79 anos, e sua detecção precoce, pode ser um aspecto vital para a segurança desses indivíduos (Ahmed *et al.*, 2025). Um sistema de monitoramento robótico ou um aplicativo de *smartphone* que analisa a pose de uma pessoa em sua residência pode ser extremamente útil para alertar cuidadores sobre situações de perigo (Kim *et al.*, 2023).

Entretanto, a complexidade do reconhecimento de atividades humanas a partir de vídeo, que inclui variações de ponto de vista, movimento da câmera, escala, pose do ator e diferentes condições de iluminação, torna o reconhecimento preciso das ações uma tarefa árdua (Wang *et al.*, 2021). A interação de sistemas computacionais baseados em IA com o comportamento humano exige que os modelos não apenas classifiquem ações simples, mas também ações complexas, compreendam nuances e se adaptem a cenários diversos do mundo real.

Neste contexto, este trabalho propõe uma abordagem prática para reconhecimento de atividades humanas a partir de vídeo baseada no uso de redes neurais profundas associadas à

fusão de características visuais e posturais. A compreensão visual é obtida com uso da rede neural convolucional modelo *EfficientNetV2* e associada a extração de informações posturais precisas com uso do *framework MediaPipe*, permitindo a classificação eficaz da atividade com uso da rede neural recorrente modelo LSTM. Com esta abordagem multimodal, espera-se obter sistemas computacionais que interpretem o comportamento humano de forma mais holística, superando as limitações de abordagens unimodais.

2. METODOLOGIA

A compreensão da atividade humana a partir de vídeo exige mais do que apenas a análise visual. Ela demanda uma interpretação aprofundada da forma e do movimento do corpo humano. A fusão de diferentes tipos de informações visuais e posturais é fundamental para alcançar uma compreensão eficiente. Para alcançar esse objetivo, neste trabalho é proposta uma abordagem baseada no emprego de múltiplas ferramentas, que incluem redes neurais artificiais profundas e algoritmos de processamento de vídeo.

2.1 Extração de informações visuais com EfficientNetV2

Para a extração de características visuais é empregada a rede neural convolucional modelo *EfficientNetV2*, uma das mais utilizadas para esta tarefa. Desenvolvida para ser altamente eficiente em termos de parametrização e velocidade de treinamento, a *EfficientNetV2* trouxe inovações no projetos de redes neurais convolucionais, superando modelos baseados em arquitetura de busca neural, como o *AmoebaNet* e o *NASNet* (Tan; Le, 2019). Seus aperfeiçoamentos, como a busca de arquitetura neural sensível ao treinamento, permitem que o modelo capture de forma eficiente o rico contexto de uma cena. Por exemplo, em uma aplicação de análise de atividades de idosos, a *EfficientNetV2* pode identificar o ambiente (quarto, sala de estar) e a presença de objetos (cadeiras, camas), fornecendo informações cruciais para a interpretação de uma ação (Lütolf-Carroll; Joshi, 2018).

2.2 Extração de informações posturais com MediaPipe

A pose humana desempenha um papel fundamental na compreensão dos movimentos e atividades. O *framework MediaPipe* é uma ferramenta altamente eficaz para detectar pontos-chaves do corpo humano em tempo real, sendo otimizada para aplicações em dispositivos de borda. Ao contrário de modelos que dependem apenas de pixels, o *MediaPipe* fornece uma estimativa de 33 *landmarks* de pose 3D, oferecendo uma compreensão geométrica do corpo e de seus movimentos. Essa capacidade é vital para aplicações como a detecção de quedas (Ahmed *et al.*, 2025) e a análise de desempenho em esportes, onde a trajetória e a posição de cada articulação são mais importantes que a aparência geral (Yeung *et al.*, 2025). O uso do *MediaPipe* também permite que aplicações possam ser executadas em dispositivos de baixo poder computacional, como por exemplo smartphones, o que o torna ideal para soluções de HAR voltadas para uso em ambientes domésticos.

2.3 Fusão de características visuais e posturais para HAR

A fusão de características visuais e posturais é um elemento chave para um sistema HAR eficiente. Apenas a análise visual com uso de uma rede neural convolucional pode ser enganosa, uma vez que o modelo pode ter dificuldades em distinguir uma atividade por causa de oclusões ou do fundo da cena, por exemplo (Lütolf-Carroll; Joshi, 2018). Da mesma forma, a análise

apenas da pose com uso de algoritmos de processamento de vídeo, pode perder informações contextuais essenciais, como a interação com objetos (Bhatnagar *et al.*, 2022).

Desta forma, a combinação das informações visuais e posturais permite uma compreensão mais completa da cena. Neste trabalho, o sistema HAR utiliza a *EfficientNetV2* para processar o *frame* de vídeo completo e extrair um vetor de características visuais que captura o contexto. Paralelamente, o *MediaPipe* é usado para extrair as coordenadas 3D dos *landmarks* da pose, que são convertidas em um vetor de características posturais. Esses dois vetores são então concatenados e utilizados como entrada em um classificador de atividades empregando uma rede neural recorrente modelo LSTM. Essa abordagem multimodal capacita o sistema HAR a interpretar ações de forma análoga à percepção humana, que considera tanto o movimento corporal quanto o ambiente em que ele ocorre.

2.4 Classificação de atividades humanas com LSTM

A natureza sequencial das atividades humanas exige modelos de classificadores que possam capturar dependências temporais. Uma queda, por exemplo, não é um único *frame*, mas uma série de movimentos que se desdobram ao longo do tempo. Para lidar com esse aspecto das atividades humanas, o modelo de rede neural profunda LSTM é particularmente adequado.

As LSTMs são um tipo de rede neural recorrente que se destaca no processamento de dados sequenciais, como *frames* de vídeo, por sua capacidade de manter um "estado" ou "memória" de longo prazo, superando as limitações das redes neurais recorrentes tradicionais (Wang *et al.*, 2021). O princípio de funcionamento de um sistema HAR baseado em LSTM é que a rede aprende a ler a sequência de vetores de características (combinando dados visuais e posturais) e a classificar a atividade com base no padrão temporal geral.

2.5. Fluxo de processamento de dados

Para viabilizar a fusão de informações visuais e posturais e preparar os dados para o treinamento e validação do classificador, é empregado um fluxo de processamento de dados que integra as saídas dos extratores de características em uma única estrutura de dados. Este processo é crucial para transformar vídeos brutos em um formato que o classificador possa utilizar eficientemente.

Inicialmente, para cada vídeo, é extraída uma sequência de *frames* de comprimento fixo, com um máximo de 30 *frames* por vídeo. Para vídeos mais curtos, a sequência é preenchida com vetores de zeros, uma técnica de *padding* que padroniza a entrada de forma adequada para utilização em redes tipo LSTM (Zheng *et al.*, 2021). Para cada frame dessa sequência, duas extrações de características são realizadas em paralelo.

O modelo *EfficientNetV2*, pré-treinado com a base de dados ImageNet e sem a camada de classificação, atua como um extrator de características. O *frame* de vídeo é redimensionado para 224x224 pixels e, após o pré-processamento do vídeo, os dados alimentam o modelo para gerar um vetor de 1280 *features*, que codificam a informação visual e contextual do ambiente (Tan; Le, 2019).

O modelo *MediaPipe Pose* é usado para detectar 33 *landmarks* do corpo humano. Cada *landmark* é representado por suas coordenadas 3D (x, y, z) e um valor de visibilidade. Esses valores são concatenados em um vetor de 132 elementos (33 *landmarks* x 4 valores), que representa a pose do sujeito no frame (Ahmed *et al.*, 2025).

Após a etapa de extração de características, o próximo passo é a fusão de características. Os dois vetores de características, o visual fornecido pela *EfficientNetV2* (1280 elementos) e o postural fornecido pelo *MediaPipe Pose* (132 elementos), são combinados através de concatenação. O resultado é um vetor de 1412 elementos para cada *frame*. Essa abordagem

multimodal garante que o classificador de atividades tenha acesso tanto à estrutura esquelética do movimento quanto a ricas informações contextuais que podem influenciar a ação.

Finalizando o processo, a sequência de vetores concatenados de 30 *frames* é organizada em uma *array* com a forma (30, 1412). O conjunto completo de vídeos processados é salvo em arquivos compactados, com cada arquivo representando a sequência de um vídeo. Esses arquivos são, posteriormente, empregados no treinamento e validação do classificador de atividades com a rede LSTM.

3 RESULTADOS E DISCUSSÃO

3.1 Implementação do sistema HAR

Para lidar com a grande quantidade de dados de vídeo e a variabilidade de suas durações, a otimização do fluxo de processamento de dados é essencial. Esse processo é crucial para melhorar o desempenho de modelos de aprendizagem de máquina aplicados em visão computacional, pois os dados adquiridos geralmente possuem ruídos, baixa qualidade ou diferentes níveis de desfoque (Costa *et al.*, 2022). Neste trabalho foi empregada a API `tf.data.Dataset` (TensorFlow.org, 2025) para implementar um processamento de dados entrada que evite gargalos. Foi utilizada a técnica *prefetch* no carregamento dos dados, garantindo que os modelos não fiquem ociosos. Foi utilizada também a técnica *padded batch*, que permite que os modelos processem vídeos de diferentes durações em um mesmo batch de treinamento, o que é importante para uso com dados adquiridos do mundo real.

Os modelos foram implementados empregando a API Keras (Keras.io, 2025), que viabiliza o uso de diversos modelos de aprendizagem de máquina. Para otimização desses modelos, que envolve a busca por hiperparâmetros ótimos, foi empregada a ferramenta Keras Tuner, visando automatizar esse processo e permitir o teste de diferentes configurações, afim de se encontrar os melhores modelos que se adaptem aos padrões de movimento humano. Essa abordagem sistemática é essencial para que os modelos aprendam a reconhecer e generalizar corretamente atividades de pessoas com diferentes tipos de corpo e estilos de movimento.

3.2 Avaliação de Desempenho

O sistema HAR implementado neste trabalho foi avaliado empregando duas bases de dados distintas, a *UR Fall Detection Dataset* e a *UCF-101 Dataset*. Na Fig. 1 são apresentadas, como exemplo, imagens de alguns *frames* de vídeos em diferentes cenas.

O *UR Fall Detection Dataset* é caracterizado por ser constituído de vídeos que exploram diferentes condições de iluminação, viabilizando avaliar a eficiência dos modelos em ambientes reais com condições ambientais variáveis (Kwolek & Kepski, 2014; Bian *et al.*, 2015; Ahamed *et al.*, 2023). Já o *UCF-101 Dataset* destaca-se por sua diversidade, contendo 101 categorias de ações em cenários não controlados, o que o torna um *benchmark* valioso para o reconhecimento atividades humanas em ambientes variados (Wang *et al.*, 2021; Zheng *et al.*, 2020; Tan & Le, 2020). O emprego de conjuntos de dados distintos permite avaliar de forma consistente o desempenho e robustez de modelos aplicados em sistemas HAR (Zheng, 2021; Yeung, 2024).

As métricas empregadas neste trabalho para avaliar o desempenho do sistema HAR implementado foram: *accuracy* (acurácia), *precision* (precisão), *recall* (revocação), F1-Score, Cohen's Kappa e MCC (*Matthew's Correlation Coefficient*). Essas métricas são amplamente utilizadas em trabalhos da literatura para avaliação de desempenho de modelos de aprendizagem de máquina, aplicados em tarefas que envolvam a classificação de padrões para diversas aplicações (Baldi, *et al.*, 2000).




Figura 1 – Exemplos de frames de vídeos dos datasets *UFC-101* e *UR Fall Detection*.
Fonte: o autor (2025).

Na Tab. 1 é apresentado o resultado da avaliação de desempenho do sistema HAR com vídeos da *UR Fall Detection Dataset*. Para esta base de dados, o sistema alcançou valores das métricas *accuracy*, *precision*, *recall* e F1-Score maiores que 93%, e valores das métricas Cohen's Kappa e MCC maiores que 88%, o que indica um bom desempenho do sistema no reconhecimento de ações de queda.

Tabela 1 - Avaliação de desempenho com *UR Fall Detection Dataset*

Métrica	<i>Accuracy</i>	<i>Precision</i>	<i>Recall</i>	F1-Score	Cohen's Kappa	MCC
Valor	94,17%	93,69%	94,75%	94,05%	88,12%	88,43%

Fonte: o autor (2025).

Na Tab. 2 é apresentado o resultado da avaliação de desempenho do sistema HAR com vídeos da *UCF-101 Dataset*. Para esta base de dados, o sistema alcançou valores das métricas *accuracy*, *precision*, *recall* e F1-Score maiores que 92%, e valores das métricas Cohen's Kappa e MCC maiores que 86%. Apesar dos valores das métricas serem ligeiramente inferiores em relação aos obtidos com a *UR Fall Detection Dataset*, esse resultado também indica um bom desempenho do sistema no reconhecimento de ações, uma vez que nesse caso os vídeos representam múltiplas ações, e não somente queda.

Tabela 2 - Avaliação de desempenho com *UCF-101 Dataset*

Métrica	<i>Accuracy</i>	<i>Precision</i>	<i>Recall</i>	F1-Score	Cohen's Kappa	MCC
Valor	93,28%	93,34%	92,76%	93,02%	86,04%	86,09%

Fonte: o autor (2025).

O desempenho geral alcançado pelo sistema HAR implementado a partir da abordagem proposta neste trabalho pode ser considerado superior aos obtidos em trabalhos da literatura

que empregam outras abordagens. No trabalho de Bian *et al.* (2015) é proposto um sistema de detecção de queda baseado em rastreamento de articulações empregando câmera de profundidade e classificador modelo SVM, que alcançou acurácia de 97,9%, sensibilidade 95,8% e especificidade de 100%. Entretanto, na avaliação de desempenho desse sistema foi utilizada uma base de dados gerada por simulação, e não uma base de dados de situações reais como neste trabalho. No trabalho de Oliveira *et al.* (2022) é proposto um sistema para detecção do caminhar desorientado de pacientes com doença de Alzheimer baseado em sensores IoT (*Internet of Things*) e rede neural convolucional, que alcançou precisão de 100%, revocação de 60% e F1-Score de 75%. Porém, esse sistema também foi avaliado com dados gerados por simulação e somente para um tipo de ação, diferentemente deste trabalho onde foram utilizados dados reais e de múltiplas ações.

5. CONCLUSÃO

O reconhecimento de atividades humanas a partir de vídeo constitui uma aplicação de grande utilidade em diversas áreas, especialmente em contextos que envolvam segurança e cuidado com idosos. Este propôs uma abordagem baseado no uso de redes neurais profundas e fusão de características visuais e posturais para implementação de sistemas HAR robustos e aplicáveis no mundo real.

Foi implementado um sistema HAR utilizado a rede neural convolucional modelo *EfficientNetV2* para extração das características visuais do ambiente e o *framework MediaPipe* para extração das características da pose humana. E a partir da combinação dos vetores de características visuais e posturais, foi utilizada para classificação da atividade a rede neural recorrente modelo LSTM.

O desempenho do sistema foi avaliando empregado duas bases de dados de vídeo diferentes, contendo múltiplas ações adquiridas em situações reais. Os resultados dos testes realizados com cada base de dados demonstraram que o sistema possui bom desempenho, alcançando valores de métricas que indicam uma boa capacidade do sistema em reconhecer atividades humanas. E esses resultados validam a eficácia da abordagem de fusão de características visuais e posturais na compreensão de movimentos complexos.

Como continuidade deste trabalho, propõe-se a implementação do sistema HAR com a abordagem proposta em um sistema embarcado, para reconhecimento de atividades humanas a partir de vídeos adquiridos de câmeras de baixo custo e em tempo real, voltado para aplicação em monitoramento de idosos em ambiente doméstico.

Agradecimentos

Os autores agradecem ao Programa de Pós-Graduação em Modelagem Computacional e Sistemas (PPGMCS) da Universidade Estadual de Montes Claros (UNIMONTES) pela utilização de suas dependências e infraestrutura.

REFERÊNCIAS

- Ahmed, F., Biswas, P., Rashid, A. e Khaliluzzaman, M. (2025), “Fall Detection from Indoor Videos using MediaPipe and Handcrafted Feature”, arXiv preprint arXiv:2503.01436v1.
- Baldi, P., Brunak, S., Chauvin, Y., Andersen, C. A. F., & Nielsen, H. (2000). “Assessing the accuracy of prediction algorithms for classification: An overview”. *Bioinformatics*, 16(5), 412-424. doi:10.1093/bioinformatics/16.5.412
- Bhatnagar, B. L., Xie, X., Petrov, I. A., Sminchisescu, C. e Theobalt, C. (2022), “BEHAVE: Dataset and Method for Tracking Human Object Interactions”, arXiv preprint arXiv:2204.06950v1.
- Bian, Z.-P., Hou, J., Chau, L.-P. e Magnenat-Thalmann, N. (2015), “Fall Detection Based on Body Part Tracking Using a Depth Camera”, *IEEE Journal of Biomedical and Health Informatics*, 19, 430–439.

- Costa, V. L., Teixeira, E. H., Mafra, S. e de Figueiredo, F. A. P. (2022), “Pré-processamento de imagens de baixa resolução utilizando Deep Learning baseado em um Autoencoder”, XL SIMPÓSIO BRASILEIRO DE TELECOMUNICAÇÕES E PROCESSAMENTO DE SINAIS.
- KERAS.IO. Keras 3 API documentation. Disponível em: <https://keras.io/api>. Acesso em: 10 mar. 2025.
- Kim, J.-W., Choi, J.-Y., Ha, E.-J. e Choi, J.-H. (2023), “Human Pose Estimation Using MediaPipe Pose and Optimization Method Based on a Humanoid Model”, Applied Sciences, 13, 2700.
- Kwolek, B. e Kepski, M. (2014), “Human fall detection on embedded platform using depth maps and wireless accelerometer”, Computer Methods and Programs in Biomedicine, 117, 489–501.
- Lütolf-Carroll, D. e Joshi, R. (2018), “Real-Time Human Activity Classification in Videos”, MLDS Student Research, Northwestern University.
- Oliveira, R., Feres, R., Barreto, F. e Abreu, R. (2022), “CNN for Elderly Wandering Prediction in Indoor Scenarios”, SN Computer Science, 3, 230.
- Tan, M. e Le, Q. V. (2019), “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks”, arXiv preprint arXiv:1905.11946v5.
- TENSORFLOW.ORG. tf.data.Dataset. Disponível em: https://www.tensorflow.org/api_docs/python/tf/data/Dataset. Acessado em: 20 mar. 2025.
- Wang, J., Tan, S., Zhen, X., Xu, S., Zheng, F., He, Z. e Shao, L. (2021), “Deep 3D human pose estimation: A review”, Computers in Vision and Image Understanding, 210, 103225.
- Yeung, C., Suzuki, T., Tanaka, R., Yin, Z. e Fujii, K. (2025), “AthletePose3D: A Benchmark Dataset for 3D Human Pose Estimation and Kinematic Validation in Athletic Movements”, arXiv preprint arXiv:2503.07499v2.
- Zheng, C., Zhu, S. e Ding, Z. (2021), “3D Human Pose Estimation With Spatial and Temporal Transformers”, Proceedings of the IEEE/CVF International Conference on Computer Vision, pp. 11656-11665.

HUMAN ACTIVITY RECOGNITION: A PRACTICAL APPROACH WITH DEEP NEURAL NETWORKS AND FUSION OF VISUAL AND POSTURAL FEATURES

Abstract. *This work proposes the application of deep neural networks to recognize human activities from videos, combined with the fusion of visual and postural features. The proposed approach uses the EfficientNetV2 convolutional neural network model to extract visual features and the MediaPipe framework to extract postural features from the video. The resulting data are combined and provided for activity classification using the LSTM recurrent neural network model. Experiments using videos from the UCF-101 Dataset and UR Fall Detection Dataset databases demonstrated that the proposed approach outperforms other approaches, making it a viable alternative for various applications.*

Keywords: *Human Activity Recognition, Deep Neural Networks, Feature Fusion.*